FIAP

GUSTAVO HENRIQUE LOPES REZENDE (RM)
JOÃO PAULO DIAS VENTURA (RM)
LUDSON RODRIGO MARCIANO FERNANDES (RM)
RAFAEL MEDICI (RM)
VINI DOS SANTOS PEREIRA (RM)

PIPELINE DE REDES NEURAIS PARA O GESTOR DE FROTA

Classificar a condução e achar onde a frota perde dinheiro

Trabalho da Sprint 1 do Challenge Sem Parar, apresentado à disciplina Redes Neurais Artificiais, Deep Learning e Algoritmos Genéticos, turma 1TIAPR, FIAP.

Orientadora: Profa. Juliana Scudilio Rodrigues.

São Paulo
2026

SUMÁRIO

1 PROBLEMA DE NEGÓCIO 2

1.1 Quem tem o problema 2

1.2 Qual o prejuízo 2

1.3 Como a Sem Parar pode ajudar 2

1.4 Tarefa da rede neural 2

2 DADOS 3

2.1 Quais dados e por que os escolhemos 3

2.2 De onde vêm e em que formato 3

2.3 Dados simulados: como e por quê 4

2.4 Problemas que esses dados têm 4

2.5 Dados de que a rede vai precisar 4

3 REDES NEURAIS 5

4 PIPELINE 5

5 COMO MEDIR O SUCESSO 6

6 RISCOS E LIMITES 7

6.1 O que pode dar errado 7

6.2 O que a solução não resolve 7

Não treinamos nenhuma rede nesta sprint: só planejamos. Tudo o que ainda não foi medido ou confirmado vem marcado como *[Suposição: texto assim]*. Propusemos um problema novo, como o enunciado permite; ele está perto da ideia "perceber quando algo foge do normal na operação" (FIAP, 2026).

1 PROBLEMA DE NEGÓCIO

1.1 Quem tem o problema

O gestor de frota de uma empresa cliente da Sem Parar. No pitch do nosso projeto, a persona é a Naira, gestora de 40 veículos (caminhões, vans e carros), que sabe quanto a frota gastou, mas não sabe onde perde dinheiro, o mesmo problema que o enunciado descreve (FIAP, 2026) (FLEET FORCE, 2026a).

1.2 Qual o prejuízo

Os gastos chegam espalhados: posto, pedágio, oficina, seguro, IPVA e multas (FLEET FORCE, 2026a). Dentro deles há uma parte que nenhum extrato mostra: o jeito de dirigir. Escolhemos medir frenagens e arrancadas bruscas por acreditar que pesam no consumo [Suposição: relação ainda não medida]. [Suposição: não temos o valor em reais dessa perda; o exemplo simulado só calcula outra, o motor ligado parado, de R$ 957 em um mês para um caminhão, e é dado simulado] (FLEET FORCE, 2026a)

1.3 Como a Sem Parar pode ajudar

A Sem Parar já atende frotas com Tag, Multiabastece, Gestão de Manutenção, Gestor de Multas e Seguros (FIAP, 2026). Um indicador de condução (eventos bruscos por 100 km, por veículo) completa o diagnóstico da calculadora e pode ligar-se a Multiabastece (consumo), Manutenção (desgaste) e Seguros (sinistros) [Suposição: hipóteses nossas]. O gestor descobre onde perde dinheiro e vira contato (FLEET FORCE, 2026a). [Suposição: a Sem Parar teria interesse; ainda não perguntamos a ela]

1.4 Tarefa da rede neural

Dado um trecho curto de leitura do veículo (janela de 5 segundos com aceleração e velocidade), classificar como condução normal, frenagem brusca ou arrancada brusca. É classificação supervisionada com dados tabulares, igual ao exemplo de MLP da aula de 27/10 (prever se o visitante compra) (REZENDE, 2026).

Hoje o kit detecta o evento por limite: eixo X abaixo de -0,40 g é frenagem brusca e acima de +0,30 g é arrancada brusca (FLEET FORCE, 2026b). Essa regra é a referência de comparação: a rede só vale a pena se acertar mais que ela. *[Suposição: a regra erra com*

buracos e lombadas, que geram picos parecidos com uma frenagem, e depende da posição do sensor no veículo; ainda não medimos isso]

2 DADOS

2.1 Quais dados e por que os escolhemos

Consideramos três fontes, resumidas na Tabela 1.

Tabela 1 – Fontes de dados consideradas

Fonte de dados	O que mostra	Decisão e justificativa
Acelerômetro e GPS do ESP32 (MPU6050 e NEO-6M)	aceleração e velocidade: o jeito de dirigir	Escolhida. É a única fonte que mostra a condução. O prof. Noris orientou usar o ESP32 com recursos de aula e começar por duas variáveis (FLEET FORCE, 2026d).
Planilha ou extrato de gastos (posto, pedágio, oficina)	quanto foi gasto	Já usada nas histórias de usuário da calculadora (FLEET FORCE, 2026a), mas não mostra como o veículo foi dirigido. Fica como dado de apoio.
OBD-II (computador de bordo)	consumo e rotação do motor	Mais completo, mas o prof. Noris disse que fica como evolução futura (FLEET FORCE, 2026d).

Fonte: elaborado pelos autores (2026).

2.2 De onde vêm e em que formato

Um kit ESP32 em cada veículo lê o acelerômetro e o GPS (velocidade, posição, km) e enviaria os dados por Wi-Fi/MQTT ao servidor [Suposição: ainda não testado] (FLEET FORCE, 2026a) (FLEET FORCE, 2026b). O formato é CSV, uma linha por evento, igual ao que o firmware imprime (Tabela 2).

Tabela 2 – Campos do arquivo de eventos do kit

Campo	Significado	Exemplo
timestamp_min	minuto da leitura	374
placa	veículo	DEM0C00
lat, lon	posição do GPS	-22,91496; -47,06148
velocidade_kmh	velocidade pelo GPS	85
km	quilometragem rodada	162,1
accel_pico_g	pico de aceleração no eixo X, em g	-0,51
duracao_min	duração do evento	0
rotulo	tipo do evento	frenagem_brusca

Fonte: FLEET FORCE, 2026b.

2.3 Dados simulados: como e por quê

Criamos dados de teste porque a Sem Parar não vai fornecer dados da frota (orientação do prof. Godoi) (FLEET FORCE, 2026a) e porque o kit ainda não rodou em bancada. Um script com semente fixa gera uma frota fictícia de 40 veículos e um arquivo de eventos do kit, com perfil por tipo de veículo e valores fictícios em ordem de grandeza de mercado (FLEET FORCE, 2026c). O arquivo de eventos tem 132 linhas de um único caminhão (placa DEM0C00): 101 de motor ocioso, 14 frenagens bruscas, 14 arrancadas bruscas, 2 excessos de velocidade e 1 abastecimento fora da rota. Todo dado simulado aparece com o selo "dados de demonstração" (FLEET FORCE, 2026a).

2.4 Problemas que esses dados têm

Estes são os motivos de não treinarmos agora:

a) poucos exemplos: só 28 eventos bruscos, de um veículo; é pouco para uma rede, que tende a decorar (overfitting) (REZENDE, 2026);
b) faltam janelas de condução normal: o arquivo guarda só os picos, e sem exemplos normais a rede não aprende a dizer "normal";
c) rótulo circular: o rótulo veio da própria regra por limite, e treinar com ele faria a rede imitar a regra;
d) só o pico: o campo accel_pico_g é um número por evento, sem o formato da curva de aceleração;
e) veículo único: caminhão, van e carro têm comportamentos e limites diferentes (FLEET FORCE, 2026b);
f) dados faltando ou errados em campo: o GPS perde sinal em túneis e garagens, e o sensor pode ser instalado torto *[Suposição: não sabemos quanto isso afeta a leitura]*. No Wokwi o GPS é simulado: o firmware gera sentenças NMEA de uma rota fixa Campinas-São Paulo (FLEET FORCE, 2026b);
g) privacidade: placa e posição identificam o motorista indiretamente (LGPD) *[Suposição: será preciso pseudonimizar a placa e obter o aceite antes de coletar de verdade]*.

2.5 Dados de que a rede vai precisar

Uma linha por janela de 5 s, com: viagem, veículo, tipo do veículo, pico, mínimo, média e desvio da aceleração no eixo X, velocidade média e variação da velocidade pelo GPS, e o rótulo. *[Suposição: taxa de 10 leituras por segundo e 6 features; a conferir no ESP32 real]* O rótulo deve vir de conferência humana (vídeo ou relato do motorista na bancada, Sprint 2), e não da regra.

3 REDES NEURAIS

Comparamos três arquiteturas (Tabela 3). O perceptron e a MLP foram vistos nas aulas; a LSTM foi citada como tópico na aula de 08/09 (REZENDE, 2026).

Tabela 3 – Comparação das redes

	Perceptron	**MLP (camadas ocultas)**	**LSTM (rede recorrente)**
O que é	um neurônio com pesos e bias, saída por degrau (aulas de 15/09 e 29/09)	várias camadas de neurônios com ativação ReLU e saída sigmoide ou softmax (aulas de 13/10 e 27/10)	rede que lê a sequência passo a passo e guarda memória (slides de 08/09; não aplicada em aula)
Combina com os dados?	recebe features por janela	recebe features por janela, o nosso formato tabular	pediria a curva de aceleração crua, ponto a ponto, que ainda não temos
Combina com a tarefa?	só separa classes com uma linha reta: não resolve nem o XOR; com 3 classes e leitura ruidosa fica fraco	aprende relações não lineares entre pico, média e desvio; treina em CPU; mesma ferramenta das aulas (scikit-learn, MLPClassifier)	aproveitaria a forma da curva sem criar features à mão; exige muito mais dados rotulados e é mais difícil de treinar e explicar

Fonte: elaborado pelos autores com base em REZENDE, 2026.

Escolhemos a MLP sobre features por janela, pelos motivos a seguir. a) A entrada é tabular e as classes são 3, o caso em que a MLP foi usada em aula (MLPClassifier com padronização, aula de 27/10) (REZENDE, 2026). b) A quantidade de dados prevista é pequena (esperamos milhares de janelas, não milhões [Suposição]), e a LSTM exigiria bem mais. c) O perceptron simples não separa classes que se sobrepõem, e o acelerômetro tem ruído. d) É fácil de explicar ao gestor: pico, média e desvio têm significado físico. A configuração inicial a testar tem duas camadas ocultas (16 e 8 neurônios), ativação ReLU, saída de 3 classes, parada antecipada (early stopping) e random_state fixo. [Suposição: o tamanho das camadas é só um ponto de partida; se confirma na validação] O plano B é a LSTM, numa sprint futura, se a MLP não superar a regra, com dados reais e rotulados.

4 PIPELINE

A Figura 1 mostra o caminho completo, dos dados ao resultado que chega ao gestor, e a Tabela 4 detalha cada etapa. O gestor vê o resultado na tela da calculadora de frota: o indicador de eventos bruscos por 100 km de cada veículo, comparado com a mediana da própria frota (benchmark, a US02) e somado às alavancas de economia (economia potencial, a US03). US02 e US03 são histórias de usuário da calculadora (FLEET FORCE, 2026a). [Suposição: o indicador entra como coluna do painel; o desenho da tela ainda não existe]

Figura 1 – Pipeline proposta, dos dados ao resultado para o gestor



Fonte: elaborada pelos autores (2026).

Tabela 4 – Etapas da pipeline

Etapa	O que faz	Cuidado
1 Dados	o ESP32 lê acelerômetro e GPS e envia por MQTT	calibrar o eixo X na instalação
2 Armazenamento	grava a leitura bruta, sem apagar nada (PostgreSQL, segundo a arquitetura do Briefing)	pseudonimizar a placa (LGPD)
3 Tratamento	remove leituras sem GPS, duplicadas e valores impossíveis (aceleração acima de ±2 g, velocidade acima de 200 km/h)	limites *[Suposição: a confirmar com o MPU6050 real]*
4 Janelas e features	recorta janelas de 5 s e calcula pico, mínimo, média e desvio da aceleração, velocidade média e variação de velocidade	descartar janelas que cruzam o fim da viagem
5 Normalização e divisão	StandardScaler com fit só no treino; divide em treino, validação e teste por viagem, nunca por linha	dividir por linha deixa janelas vizinhas em treino e teste (vazamento de dados, como na Aula 7 de ML)
6 Treino	a MLP aprende com as janelas de treino; o treino para quando o erro da validação piora	classes desbalanceadas: usar pesos por classe
7 Teste	mede recall e F1 por classe em viagens nunca vistas e compara com a regra por limite	ver a seção 5
8 Resultado para o gestor	conta eventos bruscos por 100 km de cada veículo e envia ao benchmark e à economia	é estimativa, não prova de economia

Fonte: elaborado pelos autores (2026).

5 COMO MEDIR O SUCESSO

A acurácia sozinha engana se quase toda janela for de condução normal [Suposição: ainda sem janelas reais]. Nas aulas só vimos a acurácia; usaremos recall e F1 por classe e a matriz de confusão, num teste com viagens e veículos que a rede não viu.

a) Sucesso técnico: a MLP supera a regra por limite no F1 médio das 3 classes. *[Suposição: meta de +5 pontos percentuais sobre a regra; é um valor nosso, sem base ainda]*

b) Sucesso para o negócio: menos falsos alarmes por 100 km e um indicador de condução que o gestor entenda e use no ranking de economia.
c) Parar e rever se: a rede só imitar a regra, ou se o resultado depender de uma viagem específica.

6 RISCOS E LIMITES

6.1 O que pode dar errado

a) Dados simulados: um bom resultado em dados simulados não vale para a estrada. Mitigação: coletar na bancada e validar com rótulo humano.
b) Overfitting: com poucos dados a rede decora. Mitigação: early stopping, validação por viagem e, se preciso, regularização (REZENDE, 2026).
c) Vazamento de dados: normalizar ou dividir errado infla a métrica. Mitigação: a ordem da etapa 5.
d) Mudança entre veículos: o que é brusco num carro não é num caminhão. Mitigação: limite por tipo de veículo ou o tipo como feature.
e) LGPD e confiança: medir o motorista pode gerar resistência. Mitigação: dados agregados e aviso claro.

6.2 O que a solução não resolve

a) Não recebe os dados da frota em vários formatos (planilha, foto, print): isso é outro problema, da lista do enunciado, e não é tratado aqui.
b) Não prova que o jeito de dirigir causa o gasto: a ligação entre eventos bruscos e consumo é uma hipótese nossa *[Suposição: a validar com dados reais de abastecimento]*.
c) Não cobre veículos sem o kit e não diz o motivo de um pico (buraco, lombada ou frenagem de verdade).
d) Não estima em reais quanto o gestor economiza; isso depende da US03 e de dados reais.

REFERÊNCIAS

FIAP. **Sprint 1: do problema de negócio à pipeline de redes neurais**. Enunciado da atividade da disciplina Redes Neurais Artificiais, Deep Learning e Algoritmos Genéticos. São Paulo: FIAP, 2026. Material do Portal do aluno.

FLEET FORCE. **Briefing do Challenge**: Sprint 1. São Paulo, 2026a. Documento interno da equipe.

FLEET FORCE. **Kit embarcado Fleet Force no Wokwi**: README. São Paulo, 2026b. Documento interno da equipe.

FLEET FORCE. **Simulados passo a passo** e arquivo eventos_iot_simulado.csv. São Paulo, 2026c. Documento interno da equipe.

FLEET FORCE. **Sprint 1 do Challenge**: plano e cronograma, com a orientação do prof. Noris. São Paulo, 2026d. Documento interno da equipe.

REZENDE, Gustavo Henrique Lopes. **Anotações das aulas de Redes Neurais, Deep Learning e Algoritmos Genéticos** (01/09 a 27/10/2026) e da Aula 7 de Machine Learning. São Paulo, 2026. Material pessoal.