SPRINT 1 · CHALLENGE SEM PARAR · REDES NEURAIS

Pipeline de redes neurais para o gestor de frota

Classificar a condução e achar onde a frota perde dinheiro

Trabalho da Sprint 1 do Challenge Sem Parar, apresentado à disciplina Redes Neurais Artificiais, Deep Learning e Algoritmos Genéticos, turma 1TIAPR, FIAP.
Orientadora: Profa. Juliana Scudilio Rodrigues.

FIAP · TURMA 1TIAPR · EQUIPE FLEET FORCE

GUSTAVO HENRIQUE LOPES REZENDE	RM
JOÃO PAULO DIAS VENTURA	RM
LUDSON RODRIGO MARCIANO FERNANDES	RM
RAFAEL MEDICI	RM
VINI DOS SANTOS PEREIRA	RM

SÃO PAULO · 2026

0 Resumo em números

CLASSES DE CONDUÇÃO	REDES COMPARADAS	ETAPAS DA PIPELINE	EVENTOS SIMULADOS
3	**3**	**8**	**132**
normal, frenagem brusca e arrancada brusca	Perceptron, MLP (escolhida) e LSTM	do sensor ESP32 ao resultado para o gestor	de um único caminhão; só 28 são bruscos

> Não treinamos nenhuma rede nesta sprint: só planejamos. Tudo o que ainda não foi medido ou confirmado vem marcado como **SUPOSIÇÃO** texto assim. Propusemos um problema novo, como o enunciado permite; ele está perto da ideia "perceber quando algo foge do normal na operação" (FIAP, 2026).

1 Problema de negócio

1.1 Quem tem o problema

O gestor de frota de uma empresa cliente da Sem Parar. No pitch do nosso projeto, a persona é a Naira, gestora de 40 veículos (caminhões, vans e carros), que sabe quanto a frota gastou, mas não sabe onde perde dinheiro, o mesmo problema que o enunciado descreve (FIAP, 2026) (FLEET FORCE, 2026a).

1.2 Qual o prejuízo

Os gastos chegam espalhados: posto, pedágio, oficina, seguro, IPVA e multas (FLEET FORCE, 2026a). Dentro deles há uma parte que nenhum extrato mostra: o jeito de dirigir. Escolhemos medir frenagens e arrancadas bruscas por acreditar que pesam no consumo **SUPOSIÇÃO** relação ainda não medida. **SUPOSIÇÃO** não temos o valor em reais dessa perda; o exemplo simulado só calcula outra, o motor ligado parado, de R$ 957 em um mês para um caminhão, e é dado simulado (FLEET FORCE, 2026a)

1.3 Como a Sem Parar pode ajudar

A Sem Parar já atende frotas com Tag, Multiabastece, Gestão de Manutenção, Gestor de Multas e Seguros (FIAP, 2026). Um indicador de condução (eventos bruscos por 100 km, por veículo) completa o diagnóstico da calculadora e pode ligar-se a Multiabastece (consumo), Manutenção (desgaste) e Seguros (sinistros) **SUPOSIÇÃO** hipóteses nossas. O gestor descobre onde perde dinheiro e vira contato (FLEET FORCE, 2026a). **SUPOSIÇÃO** a Sem Parar teria interesse; ainda não perguntamos a ela

1.4 Tarefa da rede neural

Dado um trecho curto de leitura do veículo (janela de 5 segundos com aceleração e velocidade), classificar como condução normal, frenagem brusca ou arrancada brusca. É classificação supervisionada com dados tabulares, igual ao exemplo de MLP da aula de 27/10 (prever se o visitante compra) (REZENDE, 2026).

Hoje o kit detecta o evento por limite (FLEET FORCE, 2026b). Essa regra é a referência de comparação: a rede só vale a pena se acertar mais que ela.

FRENAGEM BRUSCA

abaixo de -0,40 g

eixo X do acelerômetro

ARRANCADA BRUSCA

acima de +0,30 g

eixo X do acelerômetro

SUPOSIÇÃO a regra erra com buracos e lombadas, que geram picos parecidos com uma frenagem, e depende da posição do sensor no veículo; ainda não medimos isso

2 Dados

2.1 Quais dados e por que os escolhemos

Consideramos três fontes, resumidas na Tabela 1.

Tabela 1 Fontes de dados consideradas

Fonte de dados	O que mostra	Decisão e justificativa
Acelerômetro e GPS do ESP32 (MPU6050 e NEO-6M)	aceleração e velocidade: o jeito de dirigir	**Escolhida** **É a única fonte que mostra a condução. O prof. Noris orientou usar o ESP32 com recursos de aula e começar por duas variáveis (FLEET FORCE, 2026d).**
Planilha ou extrato de gastos (posto, pedágio, oficina)	quanto foi gasto	**Apoio** Já usada nas histórias de usuário da calculadora (FLEET FORCE, 2026a), mas não mostra como o veículo foi dirigido. Fica como dado de apoio.
OBD-II (computador de bordo)	consumo e rotação do motor	**Evolução futura** Mais completo, mas o prof. Noris disse que fica como evolução futura (FLEET FORCE, 2026d).

Fonte: elaborado pelos autores (2026).

2.2 De onde vêm e em que formato

Tabela 2 Campos do arquivo de eventos do kit

Campo	Significado	Exemplo
`timestamp_min`	minuto da leitura	374
`placa`	veículo	DEM0C00
`lat, lon`	posição do GPS	-22,91496; -47,06148
`velocidade_kmh`	velocidade pelo GPS	85
`km`	quilometragem rodada	162,1
`accel_pico_g`	pico de aceleração no eixo X, em g	-0,51
`duracao_min`	duração do evento	0
`rotulo`	tipo do evento	frenagem_brusca

Fonte: FLEET FORCE, 2026b.

Um kit ESP32 em cada veículo lê o acelerômetro e o GPS (velocidade, posição, km) e enviaria os dados por Wi-Fi/MQTT ao servidor **SUPOSIÇÃO** ainda não testado (FLEET FORCE, 2026a) (FLEET FORCE, 2026b). O formato é CSV, uma linha por evento, igual ao que o firmware imprime (Tabela 2).

2.3 Dados simulados: como e por quê

Criamos dados de teste porque a Sem Parar não vai fornecer dados da frota (orientação do prof. Godoi) (FLEET FORCE, 2026a) e porque o kit ainda não rodou em bancada. Um script com semente fixa gera uma frota fictícia de 40 veículos e um arquivo de eventos do kit, com perfil por tipo de veículo e valores fictícios em ordem de grandeza de mercado (FLEET FORCE, 2026c). O arquivo de eventos tem 132 linhas de um único caminhão (placa DEM0C00). Todo dado simulado aparece com o selo "dados de demonstração" (FLEET FORCE, 2026a).



2.4 Problemas que esses dados têm

Estes são os motivos de não treinarmos agora:

a **poucos exemplos:** só 28 eventos bruscos, de um veículo; é pouco para uma rede, que tende a decorar (overfitting) (REZENDE, 2026);

b **faltam janelas de condução normal:** o arquivo guarda só os picos, e sem exemplos normais a rede não aprende a dizer "normal";

c **rótulo circular:** o rótulo veio da própria regra por limite, e treinar com ele faria a rede imitar a regra;

d **só o pico:** o campo `accel_pico_g` é um número por evento, sem o formato da curva de aceleração;

e **veículo único:** caminhão, van e carro têm comportamentos e limites diferentes (FLEET FORCE, 2026b);

f **dados faltando ou errados em campo:** o GPS perde sinal em túneis e garagens, e o sensor pode ser instalado torto **SUPOSIÇÃO** não sabemos quanto isso afeta a leitura. No Wokwi o GPS é simulado: o firmware gera sentenças NMEA de uma rota fixa Campinas-São Paulo (FLEET FORCE, 2026b);

g **privacidade:** placa e posição identificam o motorista indiretamente (LGPD) **SUPOSIÇÃO** será preciso pseudonimizar a placa e obter o aceite antes de coletar de verdade

2.5 Dados de que a rede vai precisar

Uma linha por janela de 5 s, com: viagem, veículo, tipo do veículo, pico, mínimo, média e desvio da aceleração no eixo X, velocidade média e variação da velocidade pelo GPS, e o rótulo. **SUPOSIÇÃO** taxa de 10 leituras por segundo e 6 features; a conferir no ESP32 real O rótulo deve vir de conferência humana (vídeo ou relato do motorista na bancada, Sprint 2), e não da regra.

3 Redes neurais

Comparamos três arquiteturas (Tabela 3). O perceptron e a MLP foram vistos nas aulas; a LSTM foi citada como tópico na aula de 08/09 (REZENDE, 2026).

Tabela 3 Comparação das redes

	Perceptron	MLP (camadas ocultas) Escolhida	LSTM (rede recorrente)
O que é	um neurônio com pesos e bias, saída por degrau (aulas de 15/09 e 29/09)	várias camadas de neurônios com ativação ReLU e saída sigmoide ou softmax (aulas de 13/10 e 27/10)	rede que lê a sequência passo a passo e guarda memória (slides de 08/09; não aplicada em aula)
Combina com os dados?	recebe features por janela	recebe features por janela, o nosso formato tabular	pediria a curva de aceleração crua, ponto a ponto, que ainda não temos
Combina com a tarefa?	só separa classes com uma linha reta: não resolve nem o XOR; com 3 classes e leitura ruidosa fica fraco	aprende relações não lineares entre pico, média e desvio; treina em CPU; mesma ferramenta das aulas (scikit-learn, `MLPClassifier`)	aproveitaria a forma da curva sem criar features à mão; exige muito mais dados rotulados e é mais difícil de treinar e explicar

Fonte: elaborado pelos autores com base em REZENDE, 2026.

Escolhemos a MLP sobre features por janela, pelos motivos a seguir.

a A entrada é tabular e as classes são 3, o caso em que a MLP foi usada em aula (`MLPClassifier` com padronização, aula de 27/10) (REZENDE, 2026).

b A quantidade de dados prevista é pequena (esperamos milhares de janelas, não milhões **SUPOSIÇÃO**), e a LSTM exigiria bem mais.

c O perceptron simples não separa classes que se sobrepõem, e o acelerômetro tem ruído.

d É fácil de explicar ao gestor: pico, média e desvio têm significado físico.

Configuração inicial a testar

CAMADAS OCULTAS	ATIVAÇÃO	PARADA ANTECIPADA
16 + 8 neurônios	**ReLU** saída de 3 classes	**early stopping** e `random_state` fixo

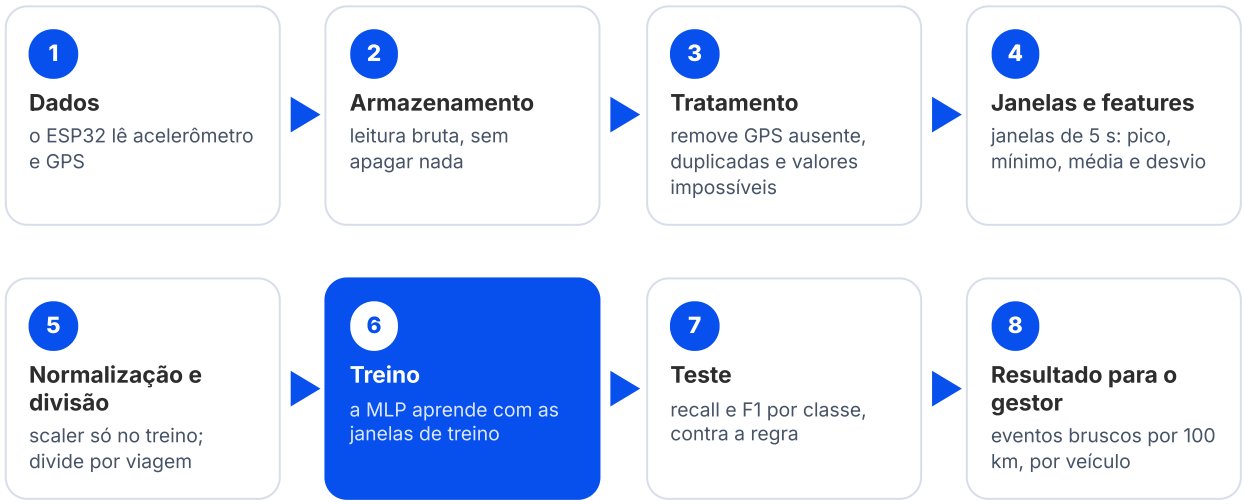
SUPOSIÇÃO o tamanho das camadas é só um ponto de partida; se confirma na validação O plano B é a LSTM, numa sprint futura, se a MLP não superar a regra, com dados reais e rotulados.

4 Pipeline

A Figura 1 mostra o caminho completo, dos dados ao resultado que chega ao gestor, e a Tabela 4 detalha cada etapa.

Figura 1 Pipeline proposta, dos dados ao resultado para o gestor

Leia da esquerda para a direita, primeiro a linha de cima.



Fonte: elaborado pelos autores (2026).

Tabela 4 Etapas da pipeline

Etapa	O que faz	Cuidado
1 Dados	o ESP32 lê acelerômetro e GPS e envia por MQTT	calibrar o eixo X na instalação
2 Armazenamento	grava a leitura bruta, sem apagar nada (PostgreSQL, segundo a arquitetura do Briefing)	pseudonimizar a placa (LGPD)
3 Tratamento	remove leituras sem GPS, duplicadas e valores impossíveis (aceleração acima de ±2 g, velocidade acima de 200 km/h)	limites **SUPOSIÇÃO** a confirmar com o MPU6050 real
4 Janelas e features	recorta janelas de 5 s e calcula pico, mínimo, média e desvio da aceleração, velocidade média e variação de velocidade	descartar janelas que cruzam o fim da viagem
5 Normalização e divisão	`StandardScaler` com fit só no treino; divide em treino, validação e teste por viagem, nunca por linha	dividir por linha deixa janelas vizinhas em treino e teste (vazamento de dados, como na Aula 7 de ML)
6 Treino	**a MLP aprende com as janelas de treino; o treino para quando o erro da validação piora**	**classes desbalanceadas: usar pesos por classe**
7 Teste	mede recall e F1 por classe em viagens nunca vistas e compara com a regra por limite	ver a seção 5
8 Resultado para o gestor	conta eventos bruscos por 100 km de cada veículo e envia ao benchmark e à economia	é estimativa, não prova de economia

Fonte: elaborado pelos autores (2026).

O que o gestor vê. O resultado aparece na tela da calculadora de frota: o indicador de eventos bruscos por 100 km de cada veículo, comparado com a mediana da própria frota (benchmark, a US02) e somado às alavancas de economia (economia potencial, a US03). US02 e US03 são histórias de usuário da calculadora (FLEET FORCE, 2026a). **SUPOSIÇÃO** o indicador entra como coluna do painel; o desenho da tela ainda não existe

5 Como medir o sucesso

A acurácia sozinha engana se quase toda janela for de condução normal **SUPOSIÇÃO** ainda sem janelas reais. Nas aulas só vimos a acurácia; usaremos recall e F1 por classe e a matriz de confusão, num teste com viagens e veículos que a rede não viu.

a) Sucesso técnico

A MLP supera a regra por limite no F1 médio das 3 classes. **SUPOSIÇÃO** meta de +5 pontos percentuais sobre a regra; é um valor nosso, sem base ainda

b) Sucesso para o negócio

Menos falsos alarmes por 100 km e um indicador de condução que o gestor entenda e use no ranking de economia.

c) Parar e rever se

A rede só imitar a regra, ou se o resultado depender de uma viagem específica.

6 Riscos e limites

6.1 O que pode dar errado

Risco	Mitigação
a) Dados simulados: um bom resultado em dados simulados não vale para a estrada.	coletar na bancada e validar com rótulo humano.
b) Overfitting: com poucos dados a rede decora.	early stopping, validação por viagem e, se preciso, regularização (REZENDE, 2026).
c) Vazamento de dados: normalizar ou dividir errado infla a métrica.	a ordem da etapa 5.
d) Mudança entre veículos: o que é brusco num carro não é num caminhão.	limite por tipo de veículo ou o tipo como feature.
e) LGPD e confiança: medir o motorista pode gerar resistência.	dados agregados e aviso claro.

6.2 O que a solução não resolve

a. Não recebe os dados da frota em vários formatos (planilha, foto, print): isso é outro problema, da lista do enunciado, e não é tratado aqui.

b. Não prova que o jeito de dirigir causa o gasto: a ligação entre eventos bruscos e consumo é uma hipótese nossa **SUPOSIÇÃO** a validar com dados reais de abastecimento.

c. Não cobre veículos sem o kit e não diz o motivo de um pico (buraco, lombada ou frenagem de verdade).

d. Não estima em reais quanto o gestor economiza; isso depende da US03 e de dados reais.

Referências

FIAP. **Sprint 1: do problema de negócio à pipeline de redes neurais**. Enunciado da atividade da disciplina Redes Neurais Artificiais, Deep Learning e Algoritmos Genéticos. São Paulo: FIAP, 2026. Material do Portal do aluno.

FLEET FORCE. **Briefing do Challenge: Sprint 1**. São Paulo, 2026a. Documento interno da equipe.

FLEET FORCE. **Kit embarcado Fleet Force no Wokwi: README**. São Paulo, 2026b. Documento interno da equipe.

FLEET FORCE. **Simulados passo a passo e arquivo eventos_iot_simulado.csv**. São Paulo, 2026c. Documento interno da equipe.

FLEET FORCE. **Sprint 1 do Challenge: plano e cronograma**, com a orientação do prof. Noris. São Paulo, 2026d. Documento interno da equipe.

REZENDE, Gustavo Henrique Lopes. **Anotações das aulas de Redes Neurais, Deep Learning e Algoritmos Genéticos** (01/09 a 27/10/2026) e da Aula 7 de Machine Learning. São Paulo, 2026. Material pessoal.